

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni prijediplomski studij Računarstvo

PRIMJENA TEHNIKA ZA OBJAŠNJENJE ISHODA
ALGORITAMA STROJNOG UČENJA NA PROBLEMU
PROCJENE KREDITNOG RIZIKA

Završni rad

Antonio Kamenski

Osijek, 2025.

Sadržaj

1. UVOD	1
1.1. Zadatak završnog rada	1
2. OBJAŠNJIVOST ALGORITMA STROJNOG UČENJA	2
2.1. Uvod u strojno učenje	2
2.2. Tehnike objašnjivosti	3
2.3. Pregled literature	6
3. OSTVARENO PROGRAMSKO RJEŠENJE	8
3.1. Problem procjene kreditnog rizika	8
3.2. Korištene tehnike objašnjivosti	9
4. EKSPERIMENTALNA ANALIZA I REZULTATI	12
4.1. Postavke i metodologija eksperimenta	12
4.2. Usporedba klasifikatora	13
4.3. Primjena tehnika objašnjivosti	15
4.3.1. Stroj potpornih vektora	15
4.3.2. Nasumična šuma	18
4.3.3. Logistička regresija	21
4.4. Diskusija rezultata	23
5. ZAKLJUČAK	25
LITERATURA	26
POPIS SLIKA	27
POPIS TABLICA	28
SAŽETAK	29
ABSTRACT	30
PRILOZI	31

1. UVOD

Strojno učenje se bavi proučavanjem i kreiranjem modela koji na temelju danih podataka donose nekakvu odluku. U srži, strojno učenje je područje umjetne inteligencije koje omogućuje računalnim sustavima da uče i poboljšavaju se iz iskustva. Model se trenira na skupovima podataka kako bi prepoznao obrasce i donio odluke temeljem tih obrazaca. Problem objašnjivosti modela u strojnom učenju pojavio se relativno nedavno s porastom složenosti samih modela strojnog učenja.

Kako je rasla složenost algoritama, tako je rasla i potreba za objašnjivošću, odnosno razumijevanjem kako algoritmi donose svoje odluke. U posljednje vrijeme, pojavili su se mnogi alati i tehnike za poboljšanje objašnjivosti algoritama koji omogućavaju vizualizaciju algoritamskih odluka i objašnjavanje na način koji je razumljiv i za stručnjake i za krajnje korisnike. Ovi alati omogućavaju analizu utjecaja pojedinačnih karakteristika na odluku modela, što doprinosi većem stupnju transparentnosti. Potreba za objašnjivosti se pojavila u brojnim domenama kao što su zdravstvo, sigurnost, pravosuđe, automatski sustavi te brojni drugi.

U kontekstu procjene kreditnog rizika, potrebno je kreirati model koji je pouzdan u donošenju odluka kako bi se osigurala adekvatna procjena kreditnog rizika i minimizirao broj loših kredita, čime se štiti financijska stabilnost banke i poboljšava kvaliteta usluga korisnicima. No tu dolazi do problema, jednostavniji modeli strojnog učenja, koji su najčešće sami po sebi objašnjivi, nisu dovoljne učinkovitosti za primjenu u analizi kreditnog rizika. Naime, modeli većih učinkovitosti su previše složeni kako bi se primijenili na ovaj problem bez dodatnog objašnjenja, jer nije jasno vidljivo kako je model došao do predikcije. Stoga se razvilo područje tehnika objašnjivosti, koje se primjenjuje na ovakvim i sličnim problemima kako bi se pokušalo detaljnije prikazati na koji način neki model dolazi do predikcije.

U drugom poglavlju opisano je područje strojnog učenja, pri čemu su objašnjeni osnovni pojmovi vezani za strojno učenje te načini vrednovanja performansi modela. Također je objašnjeno područje tehnika objašnjivosti, koje su neke od najčešćih te kako ih primijeniti. Dan je kratki osvrt na korištenu literaturu i na sami problem objašnjivosti modela strojnog učenja. U trećem poglavlju se analizira problem procjene kreditnog rizika, kako je strojno učenje primijenjeno u drugim radovima te koji su podaci od važnosti za uspješnu procjenu rizika. Dodatno, opisani su načini na koje se može vršiti procjena kreditnog rizika te važnost odabira pravog modela i pravih hiperparametara koje model koristi. Postavljena su pitanja koja će kasnije pokušati biti odgovorena te su pojašnjene tehnike objašnjivosti korištene u radu. U četvrtom poglavlju prikazana je analiza i treniranje modela na konkretnim skupovima podataka, uključujući pronalaženje i vrednovanje hiperparametara te analizu performansi modela. Potom su na svaki od tih modela primijenjene prikladne tehnike objašnjivosti, te se temelju rezultata odgovara na ranije postavljena pitanja. Konačno, izvedena je analiza rezultata te su na temelju te analize izvedeni zaključci opisani u petom poglavlju.

1.1. Zadatak završnog rada

U radu je potrebno opisati problem procjene kreditnog rizika kao klasifikacijski problem u području nadziranog strojnog učenja. Potrebno je istražiti relevantnu literaturu kako bi se utvrdio uobičajeni tijek učenja iz skupova podataka koji opisuju ovaj problem. Također, potrebno je istražiti i opisati odgovarajuće tehnike objašnjivosti modela strojnog učenja koje su uvelike korištene u literaturi, posebice za ovaj problem. U praktičnom dijelu rada nužno je razviti programsko rješenje za primjenu algoritama strojnog učenja na javno dostupnim skupovima podataka koji opisuju problem procjene kreditnog rejtinga. Uz to, na odabrane algoritme potrebno je primijeniti tehnike objašnjivosti koje će pridonijeti razumijevanju načina na koji oni donose odluke prilikom procjene kreditnog rizika.

2. OBJAŠNJIVOST ALGORITMA STROJNOG UČENJA

Strojno učenje trenutno je jedno od aktivnijih i istraživanih područja računalne znanosti, prvenstveno zbog širokog spektra primjena koje obuhvaćaju prepoznavanje uzoraka, dubinsku analizu podataka, robotiku, računalni vid, bioinformatiku i računalnu lingvistiku. Jedan od glavnih problema strojnog učenja, osim same izrade kvalitetnih modela, je njihovo interpretiranje. Problem je taj što kod velikog broja algoritama strojnog učenja nije jasno vidljivo kako je model došao do odluke. Iz tog razloga se razvilo područje tehnika objašnjivosti. Ovo poglavlje prolazi ukratko kroz osnove strojnog učenja, metode izrade modela strojnog učenja, te osnovne pojmove. U nastavku su detaljnije objašnjene tehnike objašnjivosti te njihove prednosti.

2.1. Uvod u strojno učenje

Strojno učenje se bavi proučavanjem algoritama koji na temelju prikupljenih podataka pronalaze uzorke te omogućavaju računalu da samostalno donosi neke odluke. Algoritmi strojnog učenja na temelju skupova podataka izrađuju modele koji računalima omogućuju izvođenje aktivnosti poput predviđanja, klasifikacije te donošenja odluka. S obzirom na vrste ulaznih podataka, razlikujemo nekoliko pristupa strojnog učenja. Kod nadziranog učenja, ulazni podaci uključuju atribute i očekivane izlazne vrijednosti. U nenadziranom učenju, ne postoje izlazni podatci, već se radi samo s atributima. Polunadzirano učenje kombinira ova dva pristupa: za manji dio skupa podataka postoje sve informacije kao kod nadziranog učenja, dok za veći dio nedostaju izlazne vrijednosti. Postoje i drugi pristupi koji se primjenjuju u specifičnim situacijama. Svaki skup podataka se sastoji od primjera, a primjer (engl. *instance*) je jedan unos koji sadrži vrijednosti za sve značajke. Svaki primjerak ima određeni broj elemenata, a to ovisi o broju značajki (engl. *feature*). Skup podataka se može prikazati matrično [1]

$$\mathbf{X} = \begin{bmatrix} x_1^1 & x_1^2 & \cdots & x_1^d \\ x_2^1 & x_2^2 & \cdots & x_2^d \\ \vdots & \vdots & \ddots & \vdots \\ x_N^1 & x_N^2 & \cdots & x_N^d \end{bmatrix}, \quad \mathbf{I} = \begin{bmatrix} q_1 \\ q_2 \\ \vdots \\ q_N \end{bmatrix}. \quad (2-1)$$

Matrica $\mathbf{X}$ sadrži elemente $\mathbf{x}_j^i$, gdje je j redni broj značajke, $j = 1, \dots, d$, a d predstavlja ukupan broj značajki, $i = 1, \dots, N$ predstavlja redni broj primjerka, dok N označava ukupan broj primjeraka. Svakom primjerku $\mathbf{x}$ je pridružena oznaka q . Svaki primjerak se može zapisati kao uređeni par elementa $\mathbf{x}$ i oznake $\mathbf{q}$. Ako je oznaka predstavljena kao brojčana vrijednost ili jednostavnije kao jedna od kategorija, problem nadziranog učenja se naknadno dijeli na regresiju i klasifikaciju. Regresijski algoritmi na temelju ulaznih vrijednosti pokušavaju predvidjeti neku kontinuiranu vrijednost. Klasifikacijski algoritmi na temelju ulaznih podataka pokušavaju klasificirati rezultat u jednu od unaprijed određenih klasa.

Najbitniji korak u cijelom procesu strojnog učenja je odabir prikladnog algoritma. Algoritam predstavlja matematički ili statistički postupak koji se koristi za izgradnju modela strojnog učenja na temelju ulaznih podataka. Skup podataka se prije treniranja dijeli na podskupove za treniranje i testiranje. Model se najprije trenira na podacima za treniranje, a zatim se na testnom skupu vrednuje pomoću mjera performansi. Mjere performansi su metrike koje se koriste za evaluaciju predikcijskih ili klasifikacijskih sposobnosti modela. Za klasifikaciju postoje četiri glavne mjere kod vrednovanja performansi, a to su: broj stvarno pozitivnih (engl. *true positives*, TP), broj stvarno negativnih (engl. *true negatives*, TN), broj lažno pozitivnih (engl. *false positives*, FP) te broj lažno negativnih (engl. *false negatives*, FN) predviđanja. Jedna od mjera performansi je točnost (engl. *accuracy*)

$$\text{Točnost} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (2-2)$$

koja prikazuje omjer svih točno klasificiranih instanci u odnosu na sve instance te se koristi u slučajevima kada nema dominacije niti jedne klase. Sljedeća mjera performansi je preciznost (engl. *precision*),

$$\text{Preciznost} = \frac{TP}{TP + FP}. \quad (2-3)$$

Zapisuje se kao omjer ispravno predviđenih pozitivnih rezultata u odnosu na sve predviđene pozitivne rezultate, a najčešće se koristi kada je bitno da klasifikacijski algoritam ne griješi pri predviđanju negativnih slučajeva. S druge strane, odziv (engl. *recall*) se koristi kada je bitno točno klasificirati sve pozitivne slučajeve. Računa se kao

$$\text{Odziv} = \frac{TP}{TP + FN}, \quad (2-4)$$

gdje je odziv omjer stvarno pozitivnih predviđanja u odnosu na zbroj stvarno pozitivnih i lažno negativnih predviđanja. Specifičnost (engl. *specificity*),

$$\text{Specifičnost} = \frac{TN}{TN + FP}, \quad (2-5)$$

je omjer stvarno negativnih predviđanja u odnosu na zbroj stvarno negativnih i lažno pozitivnih predviđanja, a koristi se kada je bitno smanjiti broj lažno pozitivnih rezultata. Mjera koja uravnotežuje prije navedene mjere je F1 mjera,

$$F1 = 2 \cdot \frac{\text{Preciznost} \cdot \text{Odziv}}{\text{Preciznost} + \text{Odziv}}. \quad (2-6)$$

F1 mjera se u pravilu koristi kada postoji neuravnoteženost između klasa, a predstavlja harmonijsku sredinu preciznosti i odziva.


2.2. Tehnike objašnjivosti

Modeli strojnog učenja, s obzirom na objašnjivost se dijele na dvije osnovne vrste. Te dvije vrste modela se nazivaju model bijele kutije (engl. *white-box*) i model crne kutije (engl. *black-box*). Kod modela bijele kutije postoji neki način na koji je vidljivo kako model dolazi do odluka, najčešće su to koeficijenti ili su to modeli tipa stabla, dok kod modela crne kutije to nije vidljivo. Tehnike objašnjivosti su posebno osmišljene kako bi objasnile princip rada modela crne kutije i proces donošenja zaključaka. Postoje dvije glavne vrste tehnika objašnjivosti: neovisne o modelu i ovisne o modelu. Tehnike ovisne o modelu prilagođene su specifičnim svojstvima i ponašanju modela, kako bi se postigli najbolji rezultati, te nude detaljniji opis i razumijevanje kako ti specifični modeli funkcioniraju. Tehnike koje su neovisne o modelu ne uzimaju u obzir karakteristike modela te se iz tog razloga mogu primijeniti na bilo koji model crne kutije. Jedna od jednostavnijih tehnika objašnjivosti je permutacijska važnost.

Permutacijska važnost (engl. *Permutation importance*) pokušava odrediti koliko je koja značajka bitna za model. Model se prvo trenira i vrednuje te se onda provodi postupak određivanja permutacijskih važnosti. To se radi na način da se uzmu sve vrijednosti jedne značajke i nasumično se zamijene između različitih značajki. Na taj način se značajka "izmiješa" kako bi izgubila svoj originalni redoslijed. Zatim model ponovno pravi predikcije koristeći ovaj izmiješani skup podataka, a performanse modela se uspoređuju s originalnim rezultatima. Pretpostavka je da je razlika u pogrešci između ovog vrednovanja i vrednovanja

prije miješanja vrijednosti značajke direktno povezana sa utjecajem te značajke na model. Što je značajka bitnija modelu, to bi se greška trebala pogoršati.

Tehnika parcijalne ovisnosti se nadovezuje na ovu tehniku te daje neke dodatne informacije o podacima. Grafovi parcijalne ovisnosti (engl. *Partial Dependence Plot*, PDP) se koriste za vizualizaciju kako promjena u značajkama utječe na predikciju modela. PDP se koristi na modelu koji je već treniran. Odabere se jedna značajka te se vrijednosti odabrane značajke mijenjaju na različite moguće vrijednosti iz njezinog raspona, dok ostale vrijednosti svih značajki ostanu jednake. Vrši se predikcija ciljne varijable za te izmijenjene primjere te se izračunava prosječna predikcija za različite vrijednosti te značajke. Rezultati se zatim prikazuju na grafu gdje x-os prikazuje vrijednosti značajke a y-os prikazuje prosječnu predikciju modela. Ovo omogućava interpretaciju kako promjena u toj specifičnoj značajki utječe na ishod modela, pružajući uvid u relaciju između značajke i predikcije. Uz prikaz varijabli samostalno, može se prikazati međusobna ovisnost dvaju varijabli pomoću toplinskog dijagrama. Slika 2.1 prikazuje prosječnu predikciju modela za značajke Starost i Trajanje. Na lijevom grafu je uočljivo da rast značajke Starost podiže prosječnu predikciju do otprilike 35, nakon čega se stabilizira. Na desnom grafu je uočljivo da rast značajke Trajanje konzistentno smanjuje prosječnu predikciju, pa je odnos negativan uz nešto izraženiji pad u području 30–50.



Slika 2.1: Grafički prikaz prosječne predikcije modela koristeći PDP.


Shapley aditivna objašnjenja (engl. *Shapley Additive Importance*, SHAP) je tehnika objašnjivosti koja se temelji na teoriji kooperativnih igara. SHAP koristi Shapley vrijednosti za pravednu raspodjelu doprinosa svake značajke konačnoj predikciji modela. To omogućuje dubinsko razumijevanje kako pojedinačne značajke utječu na odluke modela. Nazvana je po Lordu Shapleyu 1951. godine, koji je uveo ovaj koncept za pronalaženje rješenja u kooperativnim igrama [2]. Shapley vrijednosti pružaju kvantitativnu procjenu koliko je svaka značajka u modelu važna za predikciju. One pomažu razumjeti koje su značajke ključne za donošenje odluka modela, pružajući vrijednost doprinosa svake značajke. Za značajku i i podskup značajki S koji ne uključuje i , Shapley vrijednost ϕ_i se definira kao:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} (f(S \cup \{i\}) - f(S)), \quad (2-7)$$

gdje je N je skup svih značajki, $f(S)$ je predikcija modela koristeći podskup značajki S , $|S|$ je broj značajki u podskupu S , a $|N|$ je ukupan broj značajki.

SHAP je također moguće i grafički prikazati, što može dati još bolji uvid u odnose atributa od samih brojeva. Slika 2.2 predstavlja grafički prikaz SHAP analize. Iz dijagrama su vidljivi

sortirani atributi po njihovom utjecaju na predikciju, te je vidljiva raspodjela svakog atributa pojedinačno.



Slika 2.2: Grafički prikaz SHAP vrijednosti

Izračun SHAP vrijednosti može biti vrlo vremenski i računalno zahtjevan postupak te se stoga koriste metode aproksimacije kao što su: Kernel SHAP i Tree SHAP [3]. KernelSHAP je pristup za objašnjavanje predikcija koji je neovisan o modelu. Koristi funkciju za procjenu SHAP vrijednosti, što ga čini fleksibilnim i primjenjivim na bilo koji model strojnog učenja. Relativno je spor zbog uzorkovanja i metoda aproksimacije, te zahtijeva više evaluacija modela za svako objašnjenje. TreeSHAP je optimizirana verzija SHAP-a specifično dizajnirana za modele temeljene na stablima (stablo odluke, nasumična šuma i slični). Iskorištava strukturu ovih modela za učinkovitiji izračun Shapley vrijednosti. Optimiziran je za specifične modele, što ga čini bržim i učinkovitijim. Zbog činjenice da zapravo računa SHAP vrijednosti umjesto aproksimacije, to ga čini i preciznijim u odnosu na KernelSHAP. U tablici 2.1 je detaljnije vidljivo kada je prikladnije primijeniti koju metodu.

Lokalno interpretabilna objašnjenja neovisna o modelu (engl. *Local Interpretable Model-agnostic Explanations*, LIME) je tehnika objašnjavanja predikcija modela strojnog učenja koja omogućuje razumijevanje ponašanja složenih modela kroz jednostavne, lokalno interpretabilne modele. LIME radi na principu lokalne aproksimacije u nekoliko koraka. Prvo se odabere

Tablica 2.1: *Usporedba KernelSHAP i TreeSHAP tehnike objašnjivosti*

Aspekt	KernelSHAP	TreeSHAP
Kompatibilnost modela	Bilo koji model	Modeli temeljeni na stablima
Učinkovitost	Relativno spor zbog uzorkovanja	Brz, polinomsko vrijeme za modele stabala
Točnost	Aproksimativne Shapley vrijednosti	Točne Shapley vrijednosti
Implementacija	Neovisan o modelu, zahtijeva više evaluacija	Iskorištava strukturu stabla za učinkovitost

konkretna značajka za koji želimo objasniti predikciju. Zatim se stvara veliki broj primjeraka koji sadrže izmijenjene vrijednosti u odnosu na izvorni primjerak. Izmjene se vrše na način da im se doda šum ili da se dodaju male promjene u vrijednostima tih primjeraka. Model se zatim koristi za predviđanje izlaznih vrijednosti za svaki od generiranih izmijenjenih primjeraka. Svakom izmijenjenom primjerku se dodjeljuje težina na temelju njegove sličnosti s izvornim primjerkom. Uzorci koji su bliži izvornom primjerku dobivaju veću težinu. Zatim se model trenira na tim izmijenjenim podacima s dodanim težinama.

2.3. Pregled literature

Razvoj i popularnost tehnika objašnjivosti u strojnim učenju posljednjih su godina postali ključna tema, osobito s porastom primjene složenih modela u financijama, medicini i drugim domenama. Objašnjivost modela od izuzetne je važnosti kako bi se razumjelo zašto i kako model donosi određene odluke. Tehnike objašnjivosti poput lokalnih objašnjenja neovisnih o modelu i Shapley vrijednosti značajno su pridonijele popularnosti interpretabilnih modela [3, 4, 5].

U [6] opisuje se primjena ovih tehnika na modelima kao što su logistička regresija (engl. *logistic regression*, LR), ekstremno poboljšanje gradijenta (engl. *extreme gradient boosting*, XGB) i neuronske mreže (engl. *neural networks*), koristeći podatke koji opisuju kreditni proces. Ovaj rad naglašava kako su lokalna objašnjenja i Shapley vrijednosti važne za interpretaciju predikcija u složenim modelima kreditnog rizika. Kroz ove tehnike, korisnicima se omogućava detaljniji uvid koje su značajke najviše utjecale na odluke modela. U [7] je također naglašena važnost LIME-a i SHAP-a u kreditnom ocjenjivanju. Korištenjem podataka poljskog kreditnog biroa, autor primjenjuje ove tehnike objašnjivosti na modele poput logističke regresije i slučajne šume (engl. *random forest*, RF). Pomoću ovih tehnika, korisnici mogu detaljno analizirati kako promjene u ulaznim podacima utječu na predikcije.

Parcijalna ovisnost i važnost značajki su također važne tehnike u interpretaciji modela strojnog učenja, posebno u područjima poput kreditnog rizika. Friedman u [8] uvodi PDP grafove koji omogućuju vizualizaciju utjecaja pojedinačnih značajki na predikcije modela, dok Goldstein [5] proširuje ovu tehniku kroz tehniku individualnih uvjetnih očekivanja (engl. *individual conditional expectation*, ICE), pružajući detaljniji uvid. Ove tehnike pomažu u razumijevanju kako promjene u vrijednostima značajki utječu na rezultate modela. U kontekstu kreditnog rizika, ove tehnike pomažu u identifikaciji ključnih značajki koje utječu na odluke o riziku, čime se omogućava bolje razumijevanje i poboljšanje modela.

Tehnike objašnjivosti također su pronašle široku primjenu u medicinskom sektoru, gdje

je razumijevanje odluka modela presudno za brzinu i učinkovitost liječenja. U [9] istražuje se kako različiti modeli, uključujući stabla odluke i neuronske mreže, mogu biti objašnjeni putem tehnika kao što su parcijalna ovisnost i individualna uvjetna očekivanja. Interpretacija je ključna u područjima gdje odluke mogu imati direktan utjecaj na živote pacijenata.

Shapley vrijednosti imaju svojih prednosti i nedostataka. Kao pomoć pri objašnjavanju su izvrsne ali s obzirom da ih treba zasebno računati za svaku iteraciju, to može postati računalno jako zahtjevno. Kako bi se to pojednostavilo razvijene su metode koje ne računaju Shapley vrijednosti nego ih aproksimiraju za specifične modele. U [3] je predloženo proširenje primjene SHAP-a, predlažući modificirane verzije koje bolje odgovaraju specifičnim modelima u financijama. Tehnike objašnjivosti postale su ključne za razumijevanje složenih modela strojnog učenja, osobito u domenama poput kreditnog rizika i medicine.

Metode poput LIME-a i SHAP-a omogućile su bolje razumijevanje odluka modela, pružajući uvid u utjecaj pojedinih značajki na rezultat. Ove tehnike su posebno korisne u financijama, gdje transparentnost modela može pomoći u donošenju odluka i smanjenju rizika. Na primjer, Shapley vrijednosti omogućuju detaljniju analizu doprinosa svake značajke, dok parcijalna ovisnost i ICE grafovi pomažu u vizualizaciji utjecaja značajki na predikcije. SHAP tehnika objašnjivosti može biti računalno zahtjevna, te se s toga umjesto SHAP tehnike mogu koristiti TreeSHAP i KernelSHAP [3] kao računalno jednostavnije zamjene. Tehnike objašnjivosti koje pokušavaju prikazati slične načine objašnjavanja pružaju različite rezultate zbog različitih pristupa kvantifikaciji važnosti značajki. Stoga bi bilo korisno primijeniti više tehnika objašnjivosti na istim modelima kako bi se usporedili njihovi rezultati i stekao bolji uvid u važnost značajki. Ovo može pomoći u daljnjem poboljšanju razumijevanja modela i njihovih odluka.

3. OSTVARENO PROGRAMSKO RJEŠENJE

Cilj ovog rada je pružiti temeljito razumijevanje primjene tehnika objašnjivosti na modele strojnog učenja korištenih za procjenu kreditnog rizika. Tradicionalne metode procjene kreditnog rizika često nisu dovoljne za praćenje složenih obrazaca u velikim skupovima podataka. Strojno učenje nudi napredne metode koje mogu poboljšati pouzdanost tih procjena. Glavni cilj ovog poglavlja je pružiti duboko razumijevanje kako se algoritmi strojnog učenja mogu koristiti za procjenu kreditnog rizika. Opisano je strojno učenje kao pomoć pri donošenju odluka, uključujući osnovne pojmove i tehnike objašnjivosti. Analiziran je problem procjene kreditnog rizika, primjeri iz literature, te važnost odabira modela i hiperparametara. Također su prikazani treniranje i evaluacija modela na stvarnim podacima te primjena tehnika objašnjivosti za odgovore na postavljena pitanja. Na kraju analize izveden je kritički osvrt na korištene tehnike, istaknute su njihove glavne karakteristike te njihov način rada i prednosti.

3.1. Problem procjene kreditnog rizika

Pojam kredita je iznimno bitan za cjelokupnu ekonomiju te igra ključnu ulogu u razvoju pojedina i poduzeća. Kako bi se banke osigurale od potencijalnog gubitka novca zbog nemogućnosti vraćanja kredita, nastao je problem procjene kreditnog rizika. Postavlja se pitanje, na koji način se može odrediti je li pojedinac sposoban isplatiti kredit u cijelosti te na koji način to odrediti. Potencijalni odgovor na ovo pitanje je strojno učenje. Strojno učenje omogućuje donošenje logičnih odluka na temelju podataka koji opisuju određeni problem. Modeli se treniraju na prijašnjim instancama izdavanja kredita gdje koriste podatke iz prijašnjih slučajeva i njihove ishode kako bi poboljšali svoju učinkovitost.

Kreditni rizik može se prikazati na nekoliko načina, a najjednostavniji je prikaz rizika kao binarni ishod, gdje se može označiti kao prihvaćen ili odbijen. Osim toga, kreditni rizik može se izražavati kao postotak vjerojatnosti da će kredit biti vraćen. Klasifikacija u ovom slučaju označava je li klijent u mogućnosti vratiti posuđeni novac ili nije. Modeli za učenje koriste skupove podataka. Za te skupove se koriste podatci koji bi trebali imati utjecaj na ishod isplate kredita te oni predstavljaju ulaz u taj model. U tim skupovima podataka možemo naći značajke kao što su: spol, starost, dug, bračni status, razina obrazovanja, etnička pripadnost, godine zaposlenosti, prethodni neplaćeni dug, vozačka dozvola, državljanstvo, poštanski broj, prihod i drugi. U tablici 3.2 je vidljivo nekoliko primjeraka bankovnih klijenata koji su predali zahtjev za kredit te samo nekoliko značajki koje bi se koristile za analizu kreditnog rizika.

Tablica 3.2: *Primjer skupa podataka bankovnih klijenata*

Spol	Starost	Dug	Bračni status	Korisnik Banke	Razina Obrazovanja	Kreditni Rizik
1	34	5000	1	1	2	1
0	28	3000	0	0	3	0
1	45	8000	1	1	4	1
0	30	2000	0	1	1	0
1	50	12000	1	1	2	1

Može se također uočiti da modeli nisu jednako učinkoviti sa različitim skupovima podataka, odnosno pouzdanosti nad različitim skupovima podataka variraju. Stoga je iznimno

važno naći algoritam koji ima najveću pouzdanost s danim podacima. Isto tako je važno podesiti parametre odabranih modela, jer parametri uvelike utječu na performanse modela. Složeniji modeli često imaju veću učinkovitost u odnosu na jednostavnije modele, ali to dolazi sa nedostatkom. U složenijim modelima najčešće nije jasno kako je model došao do zaključka. Kod jednostavnijih modela, primjerice kod linearne regresije, je jednostavno odrediti kako je model došao do zaključka jer postoje težine u linearnoj kombinaciji. Misheva [6] u svom radu koristi različite modele kako bi se istražile njihove performanse u analizi kreditnog rizika. Model nasumične šume i stroj potpornih vektora (engl. *support vector machine*, SVM) koriste se za usporedbu u pogledu stabilnosti i učinkovitosti predikcija, dok neuronske mreže omogućuju modeliranje nelinearnih odnosa među značajkama. K-najbližih susjeda (engl. *k-nearest neighbours*, KNN) i analiza linearne diskriminante (engl. *linear discriminant analysis*, LDA) korišteni su u radu [7] kako bi se ispitala učinkovitost jednostavnijih metoda u odnosu na kompleksnije modele, pružajući dodatni pogled na prednosti i ograničenja svakog pristupa. U [10], osim stabala odluke (engl. *decision trees*, DT), AdaBoost algoritam i stohastičko poboljšanje gradijenta (engl. *stochastic gradient descent*, SGD) primijenjeni su za analizu kako različite tehnike poboljšanja performansi utječu na točnost modela u procjeni kreditnog rizika. Kod kreditnog rizika je jednako bitno i banci i klijentu da znaju kako je model i zbog kojih čimbenika došao do odluke. Banci je od iznimne važnosti da je klijent u mogućnosti otplatiti novac koji je posudio sa dogovorenom kamatom jer u protivnom banka gubi posuđeni novac. Ako model odluči da klijent nije sposoban vratiti kredit, tehnike objašnjivosti mogu potencijalno pružiti uvid u razlog zašto nije dobio kredit te klijent potencijalno može promijeniti neki od promatranih čimbenika kako bi ga sa sigurnošću mogao otplatiti. Iz tog razloga se na modele primjenjuju tehnike objašnjivosti.

3.2. Korištene tehnike objašnjivosti

Počevši s jednostavnijim tehnikama, jedna od tehnika korištenih u radu je permutacijska važnost (*permutation importance*, PI). Ta tehnika prikazuje koliki utjecaj svaka značajka ima na konačnu odluku modela. Također su korišteni i grafovi parcijalne ovisnosti (engl. *partial dependence plots*, PDP). Ta tehnika grafički prikazuje utjecaj promjene u vrijednosti jedne značajke na konačni rezultat. Pomoću te tehnike je moguće izolirano pratiti utjecaj pojedine značajke na izlaz modela, što je iznimno korisno ako je potrebno pojasniti potencijalne promjene koje bi se mogle napraviti kako bi se rezultat promijenio. Primjerice, kakav bi utjecaj povećanje plaće imalo na konačnu predikciju. Shapley tehnika radi tako što pripisuje doprinos svake značajke konačnoj predikciji, a te se vrijednosti mogu vizualno prikazati na velikom broju različitih grafova koji bi nam mogli dati bolji uvid na rad samog modela. Također se koriste i TreeSHAP i KernelSHAP, modificirane verzije SHAP tehnike. Jedna od tehnika korištenih u radu je LIME. LIME za jedan primjerak generira perturbirane verzije podataka i zatim trenira jednostavan, interpretabilan model koji približava predikcije složenog modela za tu instancu. Rezultati iz ovog jednostavnog modela koriste se za objašnjavanje utjecaja značajki na odluku modela. Sve ove tehnike do sada navedene su neovisne o modelu i lako primjenjive te se s toga često koriste pri objašnjavanju modela strojnog učenja, ali nisu uvijek najbolja opcija. Za neke modele su se razvile tehnike objašnjivosti koje su specifične za taj model te daju puno bolji uvid od tehnika neovisnih o modelu. Jedna od tehnika koja je ovisna o modelu je analiza koeficijenata logističke regresije (engl. *LR Coefficients*). Pomoću koeficijenata može se direktno vidjeti koliki utjecaj svaka značajka ima na konačnu predikciju. To je vidljivo iz

$$P(Y = 1 \mid \mathbf{X}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}}, \quad (3-8)$$

gdje β_i predstavlja koeficijent koji se množi x_i -tim dijelom vektora, odnosno i -tom značajkom.

Tablica 3.3: Pregled tehnika objašnjivosti, njihovih tehničkih izlaza i pitanja u kontekstu kreditnog rizika.

Tehnika objašnjivosti	Tehnički izlazi	Pitanja u kontekstu problema
Shapley aditivna objašnjenja	Kvantificira utjecaj svake značajke na konačnu odluku modela.	Koji atribut/značajka ima najveći, a koji najmanji utjecaj u procjeni kreditnog rizika? Ima li nevažnih značajki?
Lokalno interpretabilna objašnjenja neovisna o modelu	Stvara lokalne, jednostavne modele koji prikazuju kako značajke utječu na odluku modela za specifične podatke.	Koje značajke imaju najveći utjecaj na odluku o kreditnom riziku za pojedine instance? Kako bi promjena vrijednosti značajke utjecala na odluku o odobrenju kredita za određene korisnike?
Graf parcijalne ovisnosti	Vizualizira prosječan utjecaj jedne ili dvije značajke na predikciju modela, dok se druge značajke drže konstantnima.	Kako promjena u vrijednostima značajke (ili par značajki) utječe na predikciju kreditnog rizika? Postoje li značajke koje imaju veći utjecaj pri određenim vrijednostima?
Važnost značajki modela nasumične šume	Pruž a rangiranje značajki prema njihovom doprinosu u modelu.	Koje značajke su najvažnije za procjenu kreditnog rizika? Ima li značajki koje nisu bitne za određivanje rizika?
Permutacijska važnost	Mjeri promjene u performansama modela kada se nasumično permutiraju vrijednosti značajki.	Koje značajke imaju najveći utjecaj na performanse modela?

Još jedna od tehnika je doprinos značajki nasumičnih šuma (engl. *RF Contributions*). Ta tehnika izračunava doprinose svih značajki, za klasifikaciju najčešće smanjenjem entropije. Neka od pitanja koja bi se mogla postaviti su prikazana u tablici 3.3. Sami modeli najčešće ne mogu dati odgovore na ta pitanja, no na sva ta pitanja i brojna druga koja se mogu postaviti, pokušavaju odgovoriti tehnike objašnjivosti. One služe kako bi apstraktne modele pokušale vizualno i matematički pojednostaviti kako bi korisnici dobili bolji i detaljniji uvid u sami rad modela.

4. EKSPERIMENTALNA ANALIZA I REZULTATI

Cilj ovog poglavlja je prikazati postupak izrade i odabira prikladnih modela strojnog učenja i njihovih hiperparametara te postupak analize modela primjenom tehnika objašnjivosti. Nakon toga, potrebno je analizirati rezultate kako bi se steklo bolje razumijevanje modela i njihovih odluka. Predstavljeni su analiza i rezultati treniranja modela provedenih na dva skupa podataka. Dodatno, prikazana je obuka nekoliko različitih modela, optimizacija hiperparametara te evaluacija njihovih performansi. Nakon vrednovanja i odabira prikladnih modela, primijenjene su odgovarajuće tehnike objašnjivosti kako bi se detaljno analiziralo ponašanje svakog modela i odgovorilo na prethodno postavljena pitanja. Ova analiza omogućava uvid u učinkovitost modela i doprinosi razumijevanju njihovih odluka.

4.1. Postavke i metodologija eksperimenta

Skupovi podataka korišteni u ovom radu su German Credit Data i Australian Credit Approval [11]. Prvi skup ima 20 značajki i jednu kategoričku oznaku. Imena značajki su javno dostupna pa će stoga pitanja postavljena u 3.2 biti odgovorena na temelju tog skupa. Drugi skup ima 15 značajki i jednu kategoričku oznaku, pri čemu stvarni nazivi značajki radi privatnosti nisu poznati te su promijenjeni u A_i gdje se i mijenja od jedan do 15. Oba skupa sadržavaju kombinaciju kategoričkih i kontinuiranih vrijednosti. Skup je podijeljen na skup za treniranje i skup za testiranje u omjeru 70:30%. Eksperiment je proveden 10 puta s različitom podjelom skupova kako bi se ublažio utjecaj stohastičke prirode korištenih algoritama na dobivene rezultate. Kodirane su oznake kategoričkih vrijednosti u brojčane vrijednosti kako bi se kasnije mogle ispravno koristiti u modelima te su kontinuirane vrijednosti skalirane u rasponu $[0,1]$ upotrebom min-max normalizacije. Normalizacija radi na način da sve brojeve unutar jedne značajke pretvori u brojeve u rasponu $[0,1]$ i to na način da najvećem broju dodijeli vrijednost jedan, a najmanjem vrijednost nula te su svi ostali brojevi raspoređeni u tom rasponu. Skaliranje se matematički može zapisati:

$$x_{\text{skalirano}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}, \quad (4-9)$$

gdje je x izvorna vrijednost značajke koju treba skalirati, $x_{\min}$ minimalna vrijednost značajke u skupu podataka, $x_{\max}$ maksimalna vrijednost značajke u skupu podataka, $x_{\text{skalirano}}$ skalirana vrijednost značajke. To je bitan korak u obradi podataka kako atributi s velikim vrijednostima ne bi imali veći utjecaj na odluku modela samo zbog velikih vrijednosti. Za testiranje su odabrani sljedeći modeli: stroj potpornih vektora, k -najbližih susjeda, model nasumičnih šuma, višeslojni perceptron (engl. *multilayer perceptron*, MLP), stablo odluke, logistička regresija te ekstremno poboljšanje gradijenta. Napravljena je mreža od preko 10 varijacija parametara za svaki model te su parametri podešeni za svaki skup podataka pojedinačno. Ta mreža je prikazana u tablici 4.4. Podešavanje hiperparametara se vršilo vršilo pretraživanjem mreže hiperparametara, gdje se za svaku kombinaciju hiperparametara trenira klasifikacijski model te se vrednuje unakrsnom provjerom 5 preklopa. Daljnja analiza se odvija se sa tim parametrima. Idući korak u analizi je odabir prikladnih algoritama. U tu svrhu su testirani ranije spomenuti algoritmi kako bi se odabrali najbolji za daljnju analizu. Mjere performansi koje su testirane na modelima su: točnost, preciznost, odziv i F1 vrijednost.

Tablica 4.4: *Mreža hiperparametara.*

Model	Hiperparametri
SVM	jezgra: {linearna funkcija, radijalna bazna funkcija, polinomska funkcija} stupanj polinoma: {1, 2, 3, 4, 5} C: {0.01, 0.1, 1, 10, 100}
KNN	broj susjeda: {1, 3, 5, 7, 9, 11, 13, 15, 17, 19}
RF	uzorkovanje sa vraćanjem: {Da, Ne} najveća dubina: {10, 30, 50, Beskonačno} broj procjenitelja: {20, 50, 100}
MLP	veličine skrivenih slojeva: {(10), (10,10), (10,10,10), (50), (50,50), (50,50,50)} aktivacijska funkcija: {rektificirana linearna jedinica, hiperbolički tangens, identitetska funkcija, logistička funkcija} alfa: {0.0001, 0.05}
DT	mjera nečistoće: {gini vrijednost, entropija, logaritamski gubitak} najveća dubina: {10, 30, 50, Beskonačno}
LR	stupanj polinoma: {1, 2, 3, 4, 5} C: {100, 10, 1.0, 0.1, 0.01}
XGB	broj procjenitelja: {50, 100, 150} stopa učenja: {0.01, 0.1, 0.2, 0.3} najveća dubina: {3, 5, 7, 9, 11}
GNB	Ne zahtjeva određivanje hiperparametara.

4.2. Usporedba klasifikatora

Kao što je vidljivo iz tablica 4.5 i 4.6, modeli imaju različite performanse na dva različita skupa podataka. S tim na umu, odabir modela je proveden na način da se odaberu modeli koji imaju najbolje performanse na ta dva skupa podataka. Performanse prikazane u tablicama su prosječne vrijednosti tih performansi sa standardnim devijacijama nakon višestrukog izvođenja eksperimenta, u svrhu veće preciznosti. U tablicama su podebljani rezultati tri najbolja klasifikatora, odnosno njih više ako više klasifikatora dijeli neki od tri najbolja rezultata, kako bi se jasnije prikazalo na koje algoritme je pogodno primijeniti tehnike objašnjivosti. Iz podataka je vidljivo da model stabla odluke ima uvjerljivo najgore performanse dok stroj potpornih vektora ima najbolje performanse. Modeli koji su odabrani su stroj potpornih vektora, model nasumičnih šuma i logistička regresija. Iako logistička regresija nije u tri najbolja algoritma, kada se gledaju performanse, odabrana je zbog svoje prirodne objašnjivosti. Modeli su odabrani na temelju performansi te je posebice dana pažnja na preciznost, odziv i F1 mjeru, jer u slučaju procjene kreditnog rizika cilj je smanjiti broj krivo klasificiranih slučajeva. Visoka preciznost osigurava manji broj krivo klasificiranih negativnih slučajeva, odziv osigurava da je većina pozitivnih slučajeva ispravno klasificirana te F1 mjera osigurava ravnotežu između

preciznosti i odziva.

Tablica 4.5: *Performanse korištenih klasifikatora za skup podataka German Credit Data*

	SVM	KNN	RF	MLP	DT	LR	XGB	GNB
Točnost	0.76 ± 0.02	0.75 ± 0.02	0.75 ± 0.02	0.76 ± 0.02	0.69 ± 0.02	0.76 ± 0.02	0.76 ± 0.02	0.73 ± 0.02
F1	0.84 ± 0.02	0.84 ± 0.02	0.84 ± 0.02	0.84 ± 0.02	0.78 ± 0.02	0.84 ± 0.02	0.84 ± 0.02	0.80 ± 0.02
Preciznost	0.78 ± 0.02	0.77 ± 0.02	0.77 ± 0.02	0.78 ± 0.02	0.77 ± 0.02	0.78 ± 0.02	0.79 ± 0.02	0.82 ± 0.02
Odziv	0.91 ± 0.02	0.92 ± 0.02	0.92 ± 0.02	0.90 ± 0.02	0.79 ± 0.02	0.90 ± 0.02	0.89 ± 0.02	0.78 ± 0.02


Tablica 4.6: *Performanse korištenih klasifikatora za skup podataka Australian Credit Approval*

	SVM	KNN	RF	MLP	DT	LR	XGB	GNB
Točnost	0.89 ± 0.02	0.72 ± 0.02	0.87 ± 0.02	0.86 ± 0.02	0.82 ± 0.02	0.81 ± 0.02	0.87 ± 0.02	0.85 ± 0.02
F1	0.83 ± 0.02	0.63 ± 0.02	0.84 ± 0.02	0.83 ± 0.02	0.78 ± 0.02	0.75 ± 0.02	0.84 ± 0.02	0.81 ± 0.02
Preciznost	0.80 ± 0.02	0.58 ± 0.02	0.84 ± 0.02	0.84 ± 0.02	0.77 ± 0.02	0.70 ± 0.02	0.85 ± 0.02	0.78 ± 0.02
Odziv	0.86 ± 0.02	0.70 ± 0.02	0.84 ± 0.02	0.82 ± 0.02	0.79 ± 0.02	0.81 ± 0.02	0.83 ± 0.02	0.85 ± 0.02


4.3. Primjena tehnika objašnjivosti

4.3.1 Stroj potpornih vektora

Iz grafa 4.3 je vidljivo da za SVM model gotovo su sve značajke od neke važnosti, posebice stanje računa (engl. account status). Dok za graf 4.4 samo nekoliko značajki ima utjecaj na konačnu odluku, a to su primarno značajke A14 i A10.




Slika 4.3: *Važnost značajki u German Credit Data skupu podataka za SVM model*




Slika 4.4: *Važnost značajki u Australian Credit Approval skupu podataka za SVM model*

Pomoću grafa parcijalne ovisnosti može se odgovarati na pitanja kako izolirana promjena jedne značajke utječe na konačni rezultat predikcije. Za prikaz parcijalne ovisnosti su odabrane dvije značajke, vrijednost kredita (engl. credit amount) i povijest kredita (engl. credit history) te je iz grafičkog prikaza vidljivo kako gotovo linearno s porastom pozitivne povijesti kredita

raste i vjerojatnost da će kredit biti otplaćen. Za značajku vrijednost kredita je vidljivo da s porastom vrijednosti, vjerojatnost otplate opada.




(a) Značajka Credit amount



(b) Značajka Credit history

Slika 4.5: Prosječne predikcije SVM modela

Grafovi 4.6a i 4.6b prikazuju u prosjeku na koji način značajke utječu na rezultat predikcije. To je prikazano smjerom i vrijednostima. Smjer pokazuje utječe li ta značajka pozitivno ili negativno na predikciju. Također je brojčano prikazano koliko ta značajka utječe na konačnu predikciju. Graf se započinje s prosječnim vrijednostima predikcije za značajke. Zatim se dodaju doprinosi tih varijabli, dobivajući konačni zbroj doprinosa. Na primjeru značajke stanje računa (engl. account status), vidljivo je da prikaz kreće od 0.31. Crvena strelica pokazuje doprinos od +0.13, što znači da ta značajka ima doprinos od 0.13. Uočljivo je da stanje računa najčešće ima iznimno pozitivan utjecaj dok veličina posjeda ima u prosjeku negativan utjecaj.




(a) Skup podataka German Credit Data

(b) Skup podataka Australian Credit Approval


Slika 4.6: Grafovi promjena SVM modela

Graf 4.7 prikazuje važnost svake značajke za određenu instancu. Značajke koje pozitivno utječu na predikciju su prikazane zelenom bojom te su okrenute u desnu stranu, dok značajke koje negativno utječu koriste crvenu boju i okrenute su na lijevu stranu. Također prikazuju za koji raspon vrijednosti značajka ima taj prikazani utjecaj. Graf 4.8 je skup vrijednosti analiza

za 20 primjeraka te pokazuje trend koje značajke imaju najveći utjecaj pri procjeni rizika. Iz grafa je uočljivo kako se pri vrhu značajke povijest kredita (engl. credit history) i stanje računa (engl. account status) pojavljuju nekoliko puta, te su velikih magnituda, što ukazuje na to da su od velike važnosti za konačnu odluku.




Slika 4.7: *Prikaz utjecaja značajki za jedan primjer koristeći LIME tehniku objašnjivosti*




Slika 4.8: *Prikaz utjecaja značajki za 20 primjera koristeći LIME tehniku objašnjivosti*

4.3.2 Nasumična šuma

Za graf 4.9 je uočljivo da veliki utjecaj u konačnoj odluci imaju trajanje kredita (engl. duration), stanje računa (engl. account status), štednja (engl. savings) te imanja (engl. property). Iz grafa 4.10 je vidljivo da za model nasumične šume ponovno samo jedna značajka ima znatniji utjecaj na konačnu odluku.




Slika 4.9: Važnost značajki u German Credit Data skupu podataka za RF model




Slika 4.10: Važnost značajki u Australian Credit Approval skupu podataka za RF model


Iz grafova 4.11a i 4.11b je vidljivo kako utjecaj vrijednosti kredita (engl. credit amount) i povijesti kredita (engl. credit history) više nije linearan. Ta nelinearnost je jasnije vidljiva na grafovima 4.11c i 4.11d gdje je i dalje vidljivo kako s porastom starosti (engl. age) raste i sigurnost otplate kredita, odnosno sa povećanjem trajanja kredita (engl. duration) sigurnost otplate otpada ali je ta nelinearnost znatno uočljivija. Ta nelinearnost se javlja zbog prirode algoritma na kojem je model baziran.




(a) Značajka *Credit amount*



(b) Značajka *Credit history*




(c) Značajka *Age*



(d) Značajka *Duration*

Slika 4.11: *Prosječne predikcije RF modela*


Graf 4.12a prikazuje da značajke stanje računa (engl. account status) i starost (engl. age) imaju značajniji negativan utjecaj. Graf 4.12b prikazuje da značajka A8 ima značajan pozitivan utjecaj.




(a) Skup podataka German Credit Data (b) Skup podataka Australian Credit Approval

Slika 4.12: Grafovi promjena RF modela

Doprinos značajki nasumičnih šuma je još jedan način određivanja doprinosa pojedinih značajki konačnoj predikciji. Iz grafa 4.14 je vidljivo kako stanje računa (engl. account status), štednja (engl. savings), te ovaj puta, svrha (engl. purpose) imaju nešto veći utjecaj u konačnoj odluci u odnosu na ostale značajke.




Slika 4.13: Doprinos značajki u German Credit Data skupu podataka



Slika 4.14: Doprinos značajki u Australian Credit Approval skupu podataka


4.3.3 Logistička regresija

Logistička regresija je model strojnog učenja koji radi na način da na temelju podataka za učenje izračunava β koeficijente, koje kasnije pri postupku predikcije množi s vektorom x , odnosno s vrijednostima značajki jedne instance. Ako se oni prikažu grafički, dobiju se grafovi 4.15a i 4.15b te oni predstavljaju najprecizniji prikaz rada modela.




Slika 4.15: Koeficijenti logističke regresije

Iz grafa 4.16 je vidljivo da za logističku regresiju značajke sada imaju nešto značajniji negativan utjecaj. Za Australian Credit Approval skup značajke A10, A5 i A14 imaju značajan, najčešće pozitivan utjecaj. Kada se usporede ovi grafovi sa grafovima kreiranim korištenjem koeficijenata modela, uočava se mnogo sličnosti, što ukazuje na to da je metoda objašnjivosti pouzdana.




Slika 4.16: *Važnost značajki u German Credit Data skupu podataka za LR model*




Slika 4.17: *Važnost značajki u Australian Credit Approval skupu podataka za LR model*

Grafovi parcijalne ovisnosti su gotovo jednaki kao i za stroj potpornih vektora te su i dalje gotovo linearni.




(a) Značajka Credit amount



(b) Značajka Credit history

Slika 4.18: Prosječne predikcije LR modela

Graf 4.19a prikazuje da u odnosu na ostale, značajka stanje računa (engl. account status) ima značajan negativan utjecaj. Graf 4.19b prikazuje da značajke A10 i A5 imaju veliki pozitivan utjecaj dok značajka A14 ima značajniji negativan utjecaj.



(a) Skup podataka German Credit Data

(b) Skup podataka Australian Credit Approval

Slika 4.19: Grafovi promjena LR modela

4.4. Diskusija rezultata

Analiziranjem rezultata, može se uočiti kako za određene modele neke značajke imaju veću važnost od drugih, a to su najčešće značajke kao stanje računa, trajanje kredita, štednja, svrha te vrijednost kredita. Također je uočljivo kako značajke poput radnog mjesta, trajanja stanovanja, spola te imanja nisu od gotovo nikakve važnosti. Najbitnije značajke se mijenjaju ovisno o modelu koji se koristi i ovisno o tehnici objašnjivosti koja se koristi. Ovisno o promatranoj tehnici objašnjivosti, neka značajka može biti od veće važnosti u odnosu na tu istu značajku prikazanu nekom drugom tehnikom. Također, uočljiva je i razlika u rezultatima ovisno o korištenom skupu podataka. Iz grafova je uočljivo kako su važnosti značajki u prvom skupu većinom uravnotežene, dok u drugom skupu samo nekoliko značajki je dovoljno za donošenje

zaključaka. Također se pomoću tih tehnika odgovorilo na prijašnje postavljena pitanja. Permutacijska važnost, važnost značajki modela nasumičnih šuma te LIME su odgovorili na pitanja važnosti značajki, odnosno ako postoje neke značajke koje su značajnije u odnosu na druge ili ako postoje neke značajke koje su nebitne. Iz tih grafova se vidi kako je uvjerljivo najbitnija značajka stanje računa te kako su spol i starost gotovo nebitni. Grafovi parcijalne ovisnosti su pak pokazali kako se promjenom vrijednosti samo jedne značajke mijenjala predikcija samog modela, što može dati bolji uvid u značajku kao zasebnu. Iz grafa parcijalne ovisnosti je vidljivo da vrijednost kredita pri manjim vrijednostima ima visoku prosječnu predikciju dok kod većih vrijednosti predikcija naglo opada iz čega se može zaključiti da je vjerojatnost otplate mala. Nešto slično se može zamijetiti kod starosti, gdje do 35-te godine života prosječna predikcija raste do određene vrijednosti te se zatim uravnoteži. Shapley vrijednosti su kvantificirale utjecaj značajki na konačnu odluku te se iz tih grafova mogao uočiti utjecaj tih značajki, uključujući njihov iznos i smjer. Pomoću Shapley vrijednosti vidljivo je kako će najveću promjenu u konačnoj predikciji izazvati značajka stanje računa te će ona za SVM i RF model biti pozitivna, dok će za LR biti negativna. Dodatno je uočljivo kako za RF model značajke trajanje i svrha (*engl. purpose*) imaju znatno veći utjecaj u odnosu na te značajke u ostalim modelima. Slično je uočljivo i kod LR modela za značajke vrijednost rate (*engl. installment rate*), te ako je osoba strani radnik (*engl. foreign worker*).

5. ZAKLJUČAK

U ovom radu istražene su tehnike objašnjivosti i njihova primjena u modeliranju kreditnog rizika. S obzirom na potrebu za transparentnošću i razumijevanjem odluka u procesu izdavanja kredita, analizirane su različite tehnike objašnjivosti koje omogućuju objašnjavanje složenih modela strojnog učenja, koje bi mogle pomoći pri procjeni kreditnog rizika. Primjena tehnika objašnjivosti, poput parcijalne ovisnosti i Shapley vrijednosti, omogućava bolji uvid način donošenja odluka modela te identificira značajke koje imaju veliki utjecaj na kreditni rizik. Ove tehnike pomažu u povećanju povjerenja korisnika u alternativne metode procjene rizika.

U literaturi se koriste brojni različiti algoritmi strojnog učenja kao i tehnike objašnjivosti, a neki od njih su korišteni u ovom radu. Detaljnom analizom literature odabrani su najčešći algoritmi strojnog učenja te su za objašnjavanje odabrani oni koji su imali najbolje performanse. Osim toga, analizirani su i tradicionalni modeli, kao što su logistička regresija i stablo odlučivanja, koji i dalje igraju značajnu ulogu zbog svoje interpretabilnosti i jednostavnosti. Dok složeniji modeli poput stroja potpornih vektora i ekstremnog poboljšanja gradijenta nude visoku učinkovitost, njihova kompleksnost često zahtijeva dodatne procese u interpretaciji rezultata.

Analizom rezultata, vidljivo je da za različite modele značajke poput stanja računa, trajanja kredita, štednje, svrhe i vrijednosti kredita često imaju veću važnost od drugih, dok značajke poput radnog mjesta, trajanja stanovanja, spola i imanja imaju malu važnost. Važnost značajki varira ovisno o korištenom modelu i tehnici objašnjivosti, kao i o skupu podataka. Permutacijska važnost i LIME pokazali su da je stanje računa najvažnija značajka, dok su spol i starost gotovo nebitni. Grafovi parcijalne ovisnosti prikazali su kako promjene u određenim značajkama, poput vrijednosti kredita i starosti, utječu na predikciju modela. Shapley vrijednosti su kvantificirale utjecaj značajki na konačnu odluku, pokazujući da stanje računa značajno utječe na predikciju, s pozitivnim učinkom za SVM i RF modele te negativnim za LR model.

Osim da vrsta modela utječe na odabranu tehniku objašnjivosti pokazano je da sami skup podataka uvelike utječe na performanse modela pri procjeni kreditnog rizika. Stoga nije moguće odlučno reći koji je model ili koja je tehnika objašnjivosti idealna za svaki slučaj, jer istina je da sve ovisi o specifičnom skupu podataka koji se koristi. Uvijek je dobro koristiti tehnike objašnjivosti kao kombinaciju više tehnika iz razloga što nije sve vidljivo korištenjem samo jedne tehnike. Ovim radom je pokazan način na koji se primjenjuju tehnike objašnjivosti te kako se interpretiraju. Također su pomoću tih tehnika odgovorena ranije postavljena pitanja i dan je detaljniji uvid u rad samih modela.

Rad je izveden sa prilično malim brojem modela strojnog učenja i tehnika objašnjivosti, stoga, rad bi se mogao proširiti na način da se testiraju neki drugi, ranije spomenutih modeli i tehnike objašnjivosti. Također bi se rad mogao proširiti dodavanjem neuronskih mreža i modela dubokog učenja, iz razloga jer imaju znatno veću preciznost u odnosu na modele strojnog učenja.

LITERATURA

- [1] Mario Dudjak. Učenje iz neuravnoteženih podataka unaprijeđenim postupcima za odabir značajki, preuzorkovanje i izgradnju radijalnih neuronskih mreža. Doktorska disertacija. 2022.
- [2] Lloyd S. Shapley. A value for n-person games. *Contributions to the Theory of Games*, 1951.
- [3] Vaishak Belle i Ioannis Papantonis. Principles and practice of explainable machine learning. *Frontiers in Big Data*, 2021.
- [4] N. Bussmann i P. Giudici i D. Marinelli i J. Papenbrock i L. Recchia. Explainable machine learning in credit risk management. *Computational Economics*, 2021.
- [5] Leonida Gianfagna i Antonio Di Cecco. Explainable ai with python. *Springer International Publishing*, 2021.
- [6] Branka Hadji Misheva i Joerg Osterrieder i Ali Hirsia i Onkar Kulkarni i Stephen Fung Lin. Explainable ai in credit risk management. *Journal of Financial Data Science*, 2021.
- [7] Przemysław Biecek i Marcin Chlebus i Janusz Gajda i Alicja Gosiewska i Anna Kozak i Dominik Ogonowski i Jakub Sztachelski i Piotr Wojewnik. Enabling machine learning algorithms for credit scoring. *Journal of Business Economics*, 2021.
- [8] Randall Davis i Andrew W. Lo i Sudhanshu Mishra i Arash Nourian i Manish Singh i Nicholas Wu i Ruixun Zhang. Explainable machine learning models of consumer credit risk. *The Journal of Financial Data Science*, 2022.
- [9] I. Rubinić. Interpretability of machine learning models on medical tabular data. 2023. Diplomski rad.
- [10] S. Shi i R. Tse i W. Luo i J. Sun. Machine learning-driven credit risk: a systemic review. *Neural Computing and Applications*, 2022.
- [11] UCI Machine Learning Repository. German credit data dataset, 1994.
- [12] Kenneth Kennedy. Credit scoring using machine learning. *Technological University Dublin*. Doktorska disertacija. 2020.
- [13] T. Bellotti i J. Crook. Support vector machines for credit scoring and discovery of significant features. *Expert Systems with Applications*, (2), 2009.
- [14] Armend Salihu and Visar Shehu. A review of algorithms for credit risk analysis. *South East European University, North Macedonia*, 2020.
- [15] K. Croxson i P. Bracke i C. Jung. Explaining why the computer says ‘no’. *FCA Insight*, 2019.
- [16] Scott M. Lundberg i Su-In Lee. A unified approach to interpreting model predictions. *Curran Associates, Inc.*, 2017.

POPIS SLIKA

2.1. Grafički prikaz prosječne predikcije modela koristeći PDP.	4
2.2. Grafički prikaz SHAP vrijednosti	5
4.3. Važnost značajki u German Credit Data skupu podataka za SVM model	15
4.4. Važnost značajki u Australian Credit Approval skupu podataka za SVM model .	15
4.5. Prosječne predikcije SVM modela	16
4.6. Grafovi promjena SVM modela	16
4.7. Prikaz utjecaja značajki za jedan primjer koristeći LIME tehniku objašnjivosti .	17
4.8. Prikaz utjecaja značajki za 20 primjera koristeći LIME tehniku objašnjivosti . .	17
4.9. Važnost značajki u German Credit Data skupu podataka za RF model	18
4.10. Važnost značajki u Australian Credit Approval skupu podataka za RF model . .	18
4.11. Prosječne predikcije RF modela	19
4.12. Grafovi promjena RF modela	20
4.13. Doprinos značajki u German Credit Data skupu podataka	20
4.14. Doprinos značajki u Australian Credit Approval skupu podataka	21
4.15. Koeficijenti logističke regresije	21
4.16. Važnost značajki u German Credit Data skupu podataka za LR model	22
4.17. Važnost značajki u Australian Credit Approval skupu podataka za LR model . .	22
4.18. Prosječne predikcije LR modela	23
4.19. Grafovi promjena LR modela	23

POPIS TABLICA

2.1. Usporedba KernelSHAP i TreeSHAP tehnike objašnjivosti	6
3.2. Primjer skupa podataka bankovnih klijenata	8
3.3. Pregled tehnika objašnjivosti, njihovih tehničkih izlaza i pitanja u kontekstu kreditnog rizika.	10
4.4. Mreža hiperparametara.	13
4.5. Performanse korištenih klasifikatora za skup podataka German Credit Data . . .	14
4.6. Performanse korištenih klasifikatora za skup podataka Australian Credit Approval	14

SAŽETAK

Problem objašnjivosti modela strojnog učenja se nalazi u brojnim domenama kao što su zdravlje, sigurnost, medicina, financije i drugi. Taj problem je postao posebno naglašen od povećanjem složenosti modela strojnog učenja. Strojno učenje se bavi proučavanjem algoritama koji na temelju podataka pokušavaju donijeti neke odluke. S obzirom da je kod problema procjene kreditnog rizika iznimno važna učinkovitost modela, preferiraju se modeli veće učinkovitosti. Takvi modeli najčešće pripadaju skupini modela crne kutije, odnosno nije jasno vidljiv način na koji je model došao do zaključka. U ovom radu se istražuje proces stvaranja modela strojnog učenja te načini vrednovanja samih modela. Provedena je analiza literature te su na temelju te analize odabrani modeli koji će se koristiti za vrednovanje performansi. Podešeni su hiperparametri odabranih modela te su potom koristeći dva skupa podataka vrednovani svi modeli na temelju raznih mjera performansi. Na temelju tih mjera su odabrana tri modela s najboljim performansama koja će se nadalje pokušati objasniti. Analizom literature su također odabrane i tehnike objašnjivosti kojima će se pokušati objasniti ranije spomenuti modeli. Konačno, primjenom tih tehnika na odabrane modele, utvrđeno je da ako se modeli žele detaljnije objasniti, potrebno je koristiti više tehnika istovremeno.

Ključne riječi: lokalno interpretabilna objašnjenja neovisna o modelu, procjena kreditnog rizika, shapley aditivna objašnjenja, strojno učenje, tehnike objašnjivosti.

ABSTRACT

Application of Techniques for Explaining the Outcomes of Machine Learning Algorithms on the Problem of Credit Risk Assessment

The problem of model explainability in machine learning is present in numerous domains, such as, healthcare, security, medicine, finance and others. The issue has become more prominent with the increase in complexity of machine learning models. Machine learning involves the analysis of the algorithms that make decisions based on the provided data. With the efficiency of machine learning models being the focus in credit risk assessment, more complex models are preferred. These higher complexity models usually fall in the category of black-box models, meaning the decision process is not transparent. This paper explores the process of creating a machine learning model, as well as the ways in which these models are evaluated. A literature review was conducted, and based on that analysis, models were selected for further testing and evaluation. The hyperparameters of the chosen models were tuned, and using two different datasets, the models were evaluated based on various performance measures. Based on these metrics, three of the best performing models were chosen to be explained using explainability techniques. The literature review also helped select explainability techniques which are to be used to try to further explain the chosen models. Finally applying these techniques on the chosen models revealed that multiple techniques should be used simultaneously if a detailed explanation is required.

Keywords: local interpretable model-agnostic explanations, credit risk assessment, shapley additive importance, machine learning, explainability techniques.

PRILOZI

Programski kod korišten u ovom završnom radu se može naći na git repozitoriju:
<https://gitlab.com/Antonio.Kamenski/credit-risk-assessment>